

Matematički fakultet, Univerzitet u Beogradu
Seminarski rad iz predmeta: Istraživanje podataka 2

Klasterovanje gramatičkih izraza lica

Autor: Miloš Krstić

Broj indeksa: 63/2021

Profesor: Mirjana Maljković Ružičić

19. jun 2026.

Sažetak

U ovom radu prikazan je postupak klasterovanja skupa podataka Grammatical Facial Expressions, preuzetog sa UCI Machine Learning Repository. Cilj rada je primena i poređenje više algoritama nenadgledanog učenja nad istim skupom podataka, kao i analiza u kojoj meri dobijeni klasteri odgovaraju stvarnim kategorijama gramatičkih izraza lica. Izvršeno je preprocesiranje podataka, skaliranje numeričkih atributa i PCA redukcija dimenzionalnosti. Nad dve verzije podataka, skaliranim skupom i PCA redukovanim skupom, primenjeno je pet algoritama: KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i Gaussian Mixture Models. Rezultati su evaluirani internim metrikama Silhouette i Davies-Bouldin, kao i eksternim metrikama ARI i NMI, koje su korišćene isključivo za naknadno poređenje sa poznatim oznakama izraza. Dobijeni rezultati pokazuju da ne postoji jedinstveno najbolji algoritam po svim metrikama. AHC daje najbolje interne metrike separacije, dok GMM i KMeans ostvaruju najbolje vrednosti eksternih metrika na pojedinim verzijama skupa podataka. Niske ARI i NMI vrednosti ukazuju na to da stvarne klase izraza nisu jasno razdvojene u izabranom prostoru atributa.

Sadržaj

Sažetak.....	2
1. Uvod.....	6
1.1. Kontekst i motivacija.....	6
1.2. Cilj rada.....	6
1.3. Struktura rada.....	6
2. Opis zadatka.....	7
2.1. Definicija problema.....	7
2.2. Istraživačka pitanja.....	7
2.3. Metodološki pristup.....	7
3. Podaci.....	8
3.1. Izvor podataka.....	8
3.2. Struktura skupa podataka.....	8
3.3. Kategorije izraza lica.....	9
3.4. Atributi i ciljni atribut.....	10
3.5. Inicijalna vizuelizacija podataka.....	10
4. Preprocesiranje podataka.....	10
4.1. Učitavanje početnih podataka.....	10
4.2. Formiranje jedinstvenog skupa podataka.....	11
4.3. Obrada oznaka klasa.....	11
4.4. Skaliranje atributa.....	11
4.5. Čuvanje preprocesiranog skupa podataka.....	12
5. Redukcija dimenzionalnosti.....	12
5.1. Motivacija za redukciju dimenzionalnosti.....	12
5.2. PCA metoda.....	12
5.3. Formiranje skaliranog i PCA skupa podataka.....	13
5.4. Vizuelizacija podataka u 2D prostoru.....	13

6. Algoritmi klasterovanja.....	14
6.1. KMeans.....	14
6.1.1. Opis algoritma.....	14
6.1.2. Izbor broja klastera.....	14
6.1.3. Implementacija i parametri.....	15
6.2. DBSCAN.....	15
6.2.1. Opis algoritma.....	15
6.2.2. Izbor parametara.....	15
6.2.3. Implementacija i obrada šuma.....	16
6.3. HDBSCAN.....	16
6.3.1. Opis algoritma.....	16
6.3.2. Izbor parametara.....	16
6.3.3. Implementacija i prednosti u odnosu na DBSCAN.....	16
6.4. Aglomerativno hijerarhijsko klasterovanje.....	17
6.4.1. Opis algoritma.....	17
6.4.2. Izbor broja klastera.....	17
6.4.3. Dendrogram i interpretacija hijerarhijske strukture.....	17
6.5. Gaussian Mixture Models.....	18
6.5.1. Opis algoritma.....	18
6.5.2. Izbor broja komponenti pomoću BIC kriterijuma.....	18
6.5.3. Implementacija i parametri.....	18
7. Evaluacione metrike.....	19
7.1. Silhouette score.....	19
7.2. Davies-Bouldin indeks.....	19
7.3. Adjusted Rand Index.....	20
7.4. Normalized Mutual Information.....	20
7.5. Noise ratio i Selection score.....	20
7.6. BIC i AIC za GMM.....	21

8. Analiza rezultata.....	21
8.1. Rezultati KMeans algoritma.....	22
8.2. Rezultati DBSCAN algoritma.....	22
8.3. Rezultati HDBSCAN algoritma.....	23
8.4. Rezultati aglomerativnog hijerarhijskog klasterovanja.....	24
8.5. Rezultati GMM algoritma.....	24
9. Finalno poređenje algoritama.....	25
9.1. Poređenje po Silhouette meri.....	25
9.2. Poređenje po Davies-Bouldin indeksu.....	26
9.3. Poređenje po ARI i NMI metrikama.....	27
9.4. Poređenje gustinskih algoritama prema odnosu šuma.....	29
9.5. Najbolji algoritmi po skupovima podataka.....	30
9.6. Tumačenje finalnih rezultata.....	30
10. Diskusija.....	31
10.1. Uticaj izbora algoritma.....	31
10.2. Uticaj PCA redukcije.....	31
10.3. Ograničenja korišćenih metrika.....	32
10.4. Ograničenja rada.....	32
11. Zaključak.....	33
11.1. Glavni rezultati rada.....	33
11.2. Odgovor na istraživačka pitanja.....	33
11.3. Moguća unapređenja i budući rad.....	34
12. Literatura.....	34

1. Uvod

Klasterovanje predstavlja jednu od osnovnih metoda nenadgledanog učenja. Njegov cilj je da se u skupu podataka pronađu grupe sličnih instanci bez korišćenja unapred poznatih oznaka klasa. Za razliku od klasifikacije, kod koje model uči na osnovu poznatih ciljnih vrednosti, klasterovanje pokušava da samostalno otkrije strukturu podataka.

1.1. Kontekst i motivacija

U ovom radu analiziran je skup podataka koji opisuje gramatičke izraze lica. Izrazi lica mogu imati različite gramatičke funkcije, kao što su potvrđivanje, negacija, pitanje, uslov, naglašavanje ili označavanje teme. Zbog toga je zanimljivo ispitati da li se uzorci koji pripadaju različitim gramatičkim kategorijama mogu automatski grupisati na osnovu numeričkih atributa koji ih opisuju.

Motivacija za rad je poređenje više algoritama klasterovanja nad istim skupom podataka. Različiti algoritmi mogu pronaći različite strukture u podacima, jer ne polaze od istih pretpostavki o obliku, gustini i raspodeli klastera. Zbog toga je potrebno analizirati njihove rezultate pomoću više metrika i proveriti da li se dobijeni klasteri poklapaju sa stvarnim kategorijama izraza.

1.2. Cilj rada

Cilj rada je da se nad skupom podataka gramatičkih izraza lica primeni više algoritama klasterovanja, da se uporede njihovi rezultati i da se proceni koliko dobijeni klasteri odgovaraju stvarnim kategorijama izraza.

U radu je korišćeno pet algoritama: KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i Gaussian Mixture Models. Svaki algoritam je primenjen nad dve verzije podataka: skaliranim skupom atributa i PCA redukovanim skupom atributa. Na taj način se ispituje i uticaj redukcije dimenzionalnosti na kvalitet klasterovanja.

Stvarne oznake izraza nisu korišćene tokom klasterovanja. One se koriste samo naknadno, za evaluaciju rezultata pomoću eksternih metrika. Time se čuva nenadgledana priroda problema, dok se istovremeno omogućava poređenje dobijenih klastera sa poznatim kategorijama.

1.3. Struktura rada

Rad je organizovan u više celina. Nakon uvoda, u drugom poglavlju opisan je zadatak, istraživačka pitanja i metodološki pristup. Treće poglavlje opisuje skup podataka, njegov izvor, strukturu i kategorije izraza lica.

Četvrto poglavlje opisuje preprocesiranje podataka, dok peto poglavlje prikazuje redukciju dimenzionalnosti pomoću PCA metode. U šestom poglavlju opisani su korišćeni algoritmi klasterovanja, a u sedmom evaluacione metrike.

Osmo poglavlje prikazuje rezultate pojedinačnih algoritama. Deveto poglavlje daje finalno poređenje algoritama nad oba skupa podataka. U desetom poglavlju diskutuje se o dobijenim rezultatima i ograničenjima rada, dok se u završnom poglavlju iznose glavni zaključci i moguća unapređenja.

2. Opis zadatka

Zadatak ovog rada je primena i poređenje različitih algoritama klasterovanja nad skupom podataka koji opisuju gramatičke izraze lica. Problem pripada oblasti nenadgledanog učenja, jer algoritmi tokom procesa klasterovanja ne koriste poznate oznake klasa, već pokušavaju da samostalno otkriju grupe sličnih instanci na osnovu numeričkih atributa.

2.1. Definicija problema

Za razliku od klasifikacije, gde bi cilj bio da se direktno predvidi kategorija izraza lica, ovde je cilj da se ispita da li se postojeće kategorije izraza prirodno pojavljuju kao klasteri u prostoru atributa. Stvarne oznake kategorija koriste se tek nakon klasterovanja, radi evaluacije i tumačenja dobijenih grupa.

U radu je korišćeno pet algoritama klasterovanja: KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i Gaussian Mixture Models. Svaki algoritam primenjen je nad dve verzije skupa podataka: skaliranim skupom atributa i PCA redukovanim skupom atributa. Na taj način omogućeno je poređenje algoritama, ali i analiza uticaja redukcije dimenzionalnosti na kvalitet klasterovanja.

Nakon primene algoritama, rezultati su evaluirani pomoću internih i eksternih metrika. Interne metrike ocenjuju geometrijski kvalitet klastera, dok eksterne metrike porede dobijene klastere sa stvarnim oznakama izraza.

2.2. Istraživačka pitanja

U okviru rada razmatrana su sledeća istraživačka pitanja:

1. Da li se gramatičke kategorije izraza lica mogu uočiti pomoću nenadgledanog klasterovanja?

Pošto algoritmi nemaju pristup stvarnim oznakama tokom rada, važno je ispitati da li se dobijeni klasteri makar delimično poklapaju sa poznatim kategorijama izraza lica.

2. Da li različiti algoritmi klasterovanja pronalaze sličnu strukturu u podacima?

Različiti algoritmi polaze od različitih pretpostavki o obliku i strukturi klastera. Zbog toga isti skup podataka može dati različite rezultate u zavisnosti od izabranog algoritma.

3. Da li PCA redukcija dimenzionalnosti poboljšava ili pogoršava rezultate klasterovanja?

PCA može ukloniti šum i redundantne informacije, ali može ukloniti i deo informacija koje su korisne za razlikovanje pojedinih kategorija. Zbog toga su svi algoritmi testirani i nad skaliranim i nad PCA redukovanim skupom.

4. Koji algoritmi daju najbolje rezultate prema internim, a koji prema eksternim metrikama?

Interne metrike ocenjuju kvalitet same strukture klastera, dok eksterne metrike mere poklapanje sa stvarnim oznakama. Zbog toga se ne mora desiti da isti algoritam bude najbolji prema svim kriterijumima.

5. Kako se ponašaju algoritmi koji mogu da označe deo podataka kao šum?

DBSCAN i HDBSCAN se razlikuju od ostalih algoritama jer ne moraju svaku instancu da dodele klasteru. Zato je kod njih posebno analiziran i odnos tačaka označenih kao šum.

2.3. Metodološki pristup

Rad je realizovan kroz nekoliko faza. Prvo su početni podaci učitani i objedinjeni u jedinstven skup pogodan za analizu. Nakon toga izvršeno je preprocesiranje, uključujući pripremu numeričkih atributa i oznaka kategorija, kao i skaliranje podataka.

Zatim je primenjena PCA redukcija dimenzionalnosti, čime je dobijena druga verzija skupa podataka. Na taj način su formirana dva skupa nad kojima se vrši klasterovanje: skalirani skup atributa i PCA redukovani skup atributa.

Nakon pripreme podataka primenjeno je pet algoritama klasterovanja. Za svaki algoritam izvršen je izbor odgovarajućih parametara, a zatim su rezultati evaluirani pomoću više metrika. Na kraju su najbolji rezultati svih algoritama objedinjeni u finalno poređenje, kako bi se analiziralo koji pristupi daju najkvalitetnije klastere i koliko se ti klasteri poklapaju sa stvarnim kategorijama izraza lica.

3. Podaci

3.1. Izvor podataka

U ovom radu korišćen je skup podataka Grammatical Facial Expressions, javno dostupan u okviru UCI Machine Learning Repository. Skup podataka namenjen je razvoju modela koji omogućavaju interpretaciju gramatičkih izraza lica u brazilskom znakovnom jeziku, odnosno Libras jeziku.

Gramatički izrazi lica predstavljaju specifičan oblik neverbalne komunikacije koji u znakovnim jezicima ima gramatičku funkciju. Za razliku od emocionalnih izraza lica, ovde cilj nije prepoznavanje emocija, već prepoznavanje izraza koji doprinose značenju rečenice, kao što su negacija, pitanje, uslov ili naglašavanje.

Originalni podaci su u projektu smešteni u direktorijum: *data/raw/*

Ovaj direktorijum sadrži tekstualne fajlove sa koordinatama odnosno numeričkim opisima tačaka lica, kao i odgovarajuće fajlove sa oznakama. Fajlovi su organizovani po kategorijama izraza i po subjektima označenim prefiksima a i b. Na primer, postoje fajlovi za kategorije affirmative, conditional, negative, wh_question i druge.

Pored originalnih podataka, u projektu su formirani i dodatni skupovi nastali obradom podataka. Preprocesirani skup sačuvan je u: *data/preprocessed/preprocessed_dataset.csv*

Skupovi korišćeni za klasterovanje sačuvani su u:

- *data/reduced/X_scaled.npy*
- *data/reduced/X_pca.npy*

Na ovaj način u projektu su dostupne početna verzija podataka, preprocesirana verzija i verzije podataka korišćene za eksperimente klasterovanja.

3.2. Struktura skupa podataka

Originalni skup podataka organizovan je kroz više tekstualnih fajlova. Za svaku kategoriju izraza postoje fajlovi koji sadrže podatke o instancama i fajlovi koji sadrže ciljne oznake. Nazivi fajlova ukazuju na subjekt, kategoriju izraza i tip podataka.

Primeri fajlova iz početnog skupa su:

- *a_affirmative_datapoints.txt*
- *a_affirmative_targets.txt*
- *a_negative_datapoints.txt*

- *a_negative_targets.txt*
- *b_wh_question_datapoints.txt*
- *b_wh_question_targets.txt*

Fajlovi sa sufiksom *datapoints* sadrže numeričke vrednosti koje opisuju položaje karakterističnih tačaka lica kroz posmatrane frejmove. Fajlovi sa sufiksom *targets* sadrže oznake koje ukazuju na pripadnost odgovarajućoj kategoriji izraza. Tokom preprocesiranja ovi fajlovi se objedinjuju u jedinstvenu tabelarnu strukturu pogodnu za analizu.

Skup podataka je sekvencijalan, jer potiče iz video zapisa i sadrži uzorke kroz vreme. Ipak, u ovom radu klasterovanje se vrši nad instancama predstavljenim numeričkim atributima, a ne nad celim video sekvencama. Drugim rečima, svaka instanca u obrađenom skupu predstavlja jedan numerički opis izraza lica u određenom trenutku.

Nakon preprocesiranja dobija se jedinstven skup podataka u kome se nalaze numerički atributi i oznaka kategorije izraza. Numerički atributi se koriste kao ulaz za algoritme klasterovanja, dok se oznaka kategorije koristi isključivo za naknadnu evaluaciju rezultata.

3.3. Kategorije izraza lica

U skupu podataka postoji devet kategorija gramatičkih izraza lica. One predstavljaju različite gramatičke funkcije koje izraz lica može imati u znakovnom jeziku. Kategorije korišćene u radu su: *affirmative*, *conditional*, *doubt_question*, *emphasis*, *negative*, *relative*, *topics*, *wh_question*, *yn_question*.

Radi preglednosti, kategorije su prikazane u sledećoj tabeli.

Oznaka kategorije	Značenje
affirmative	potvrđivanje
conditional	uslovni izraz
doubt_question	pitanje koje izražava sumnju
emphasis	naglašavanje
negative	negacija
relative	relativna konstrukcija
topics	označavanje teme
wh_question	pitanje sa upitnom reči
yn_question	da/ne pitanje

Tabela 1. Kategorije izraza lica u skupu podataka

Ove kategorije predstavljaju stvarne oznake podataka. Međutim, pošto je cilj rada klasterovanje, one nisu korišćene kao ulaz algoritmima. Njihova uloga je evaluaciona: nakon formiranja klastera proverava se koliko se dobijene grupe poklapaju sa ovim kategorijama.

3.4. Atributi i ciljni atribut

Atributi u skupu podataka predstavljaju numerički opis izraza lica. Oni potiču od karakterističnih tačaka lica koje opisuju položaje delova kao što su oči, obrve, nos, kontura lica i drugi relevantni regioni. Pošto su vrednosti numeričke, skup je pogodan za primenu algoritama klasterovanja koji se zasnivaju na udaljenostima, gustini ili verovatnosnom modelovanju.

U kontekstu ovog rada, ulazni atributi su korišćeni za formiranje klastera. To znači da algoritmi analiziraju sličnost između instanci na osnovu njihovih numeričkih vrednosti. Pre same primene algoritama, atributi su obrađeni i skalirani kako bi različite dimenzije imale uporediv uticaj na rezultat.

Ciljni atribut predstavlja kategoriju izraza lica kojoj instanca pripada. Iako se ovaj atribut može koristiti u zadacima klasifikacije, u ovom radu on nije korišćen tokom klasterovanja. Razlog je to što klasterovanje pripada nenadgledanom učenju, pa algoritmi ne treba da imaju informaciju o pravim klasama.

Ciljni atribut je ipak zadržan za naknadnu evaluaciju. Pomoću njega su izračunate eksterne metrike, kao što su Adjusted Rand Index i Normalized Mutual Information. Ove metrike omogućavaju poređenje dobijenih klastera sa stvarnim kategorijama izraza, ali ne utiču na sam proces formiranja klastera.

3.5. Inicijalna vizuelizacija podataka

Pre primene algoritama klasterovanja korisno je vizuelno prikazati podatke u prostoru manje dimenzionalnosti. Pošto originalni skup atributa ima više dimenzija, direktna vizuelizacija nije moguća. Zbog toga je primenjena PCA transformacija, kojom se podaci projektuju u prostor glavnih komponenti.

Inicijalna vizuelizacija ima ulogu da pruži prvi uvid u strukturu skupa podataka. Ako bi kategorije izraza bile jasno razdvojene, moglo bi se očekivati da se u 2D projekciji pojave odvojene grupe. Međutim, kod realnih skupova podataka često dolazi do preklapanja kategorija, naročito kada su razlike između klasa suptilne ili kada numerički atributi ne razdvajaju direktno semantičke kategorije.

Kod ovog skupa podataka vizuelizacije ukazuju da kategorije izraza lica nisu potpuno jasno razdvojene u prostoru atributa. To je važna početna informacija, jer objašnjava zašto različiti algoritmi mogu davati različite rezultate i zašto se interni kvalitet klastera ne mora nužno poklapati sa stvarnim oznakama izraza.

Ova inicijalna vizuelizacija takođe opravdava primenu više algoritama klasterovanja. Ako struktura podataka nije očigledna, nije dovoljno osloniti se samo na jedan algoritam ili jednu metriku. Umesto toga, potrebno je uporediti više pristupa i analizirati rezultate iz različitih uglova.

4. Preprocesiranje podataka

4.1. Učitavanje početnih podataka

Početni podaci su organizovani kroz više tekstualnih fajlova, podeljenih prema subjektu i kategoriji gramatičkog izraza lica. Takva organizacija je pogodna za čuvanje originalnog skupa podataka, ali nije direktno pogodna za primenu algoritama klasterovanja, jer algoritmi očekuju jedinstvenu matricu atributa.

Zbog toga je prvi korak preprocesiranja bio učitavanje svih početnih fajlova i izdvajanje numeričkih vrednosti koje opisuju izraze lica. Pored numeričkih atributa, za svaku instancu je zabeležena i kategorija

izraza kojoj pripada. Ta oznaka nije korišćena kao ulaz u algoritme klasterovanja, već je sačuvana radi kasnije evaluacije rezultata.

Učitavanje i priprema podataka realizovani su u okviru notebook-a za preprocesiranje. Na taj način je obezbeđeno da se svi fajlovi obrade na isti način i da se dobije konzistentna struktura podataka za naredne faze analize.

4.2. Formiranje jedinstvenog skupa podataka

Nakon učitavanja početnih fajlova, svi podaci su objedinjeni u jedinstven skup. Time su instance iz različitih kategorija spojene u jednu tabelarnu strukturu, pogodnu za numeričku analizu i primenu algoritama klasterovanja.

Ovaj korak je važan zato što omogućava da svi algoritmi rade nad istim skupom podataka. Da su kategorije obrađivane odvojeno, ne bi bilo moguće izvršiti zajedničko klasterovanje niti korektno poređenje rezultata. Objedinjavanjem podataka dobija se jedna matrica atributa, dok se oznake kategorija čuvaju odvojeno za evaluaciju.

Rezultat ove faze je preprocesirani skup podataka, sačuvan u fajlu *data/preprocessed/preprocessed_dataset.csv*. Ovaj fajl predstavlja osnovu za dalje transformacije, uključujući skaliranje i redukciju dimenzionalnosti.

4.3. Obrada oznaka klasa

Iako se u skupu podataka nalaze poznate kategorije izraza lica, one nisu korišćene tokom klasterovanja. Razlog za to je priroda zadatka: klasterovanje pripada nenadgledanom učenju, pa algoritmi treba da pronađu strukturu podataka bez informacija o stvarnim klasama.

Oznake klasa su ipak zadržane u obrađenom skupu podataka. Njihova uloga je evaluaciona, jer omogućavaju naknadno poređenje dobijenih klastera sa stvarnim kategorijama izraza. Na osnovu njih izračunate su eksterne metrike kao što su Adjusted Rand Index i Normalized Mutual Information.

Na ovaj način je zadržana metodološka ispravnost eksperimenta: oznake ne utiču na formiranje klastera, ali omogućavaju proveru koliko se dobijeni klasteri poklapaju sa poznatim gramatičkim kategorijama.

4.4. Skaliranje atributa

Nakon formiranja jedinstvenog skupa izvršeno je skaliranje numeričkih atributa. Ovaj korak je neophodan zato što mnogi algoritmi klasterovanja zavise od udaljenosti između instanci. Ako atributi nisu na uporedivoj skali, atributi sa većim numeričkim opsegom mogu imati veći uticaj na rezultat, čak i kada nisu informativniji od ostalih atributa.

Skaliranje je posebno važno za algoritme kao što su KMeans, DBSCAN, HDBSCAN i aglomerativno klasterovanje, jer se oni oslanjaju na pojam udaljenosti u prostoru atributa. Nakon skaliranja, svi atributi imaju uporediv uticaj na računanje sličnosti između instanci.

Dobijeni skalirani skup podataka sačuvan je kao *data/reduced/X_scaled.npy* i korišćen je kao jedna od dve glavne reprezentacije podataka u eksperimentima.

4.5. Čuvanje preprocesiranog skupa podataka

Rezultati preprocesiranja su sačuvani u posebnim fajlovima kako bi se omogućila ponovljivost celog postupka. Time se izbegava potreba da se početni podaci ponovo obrađuju pri svakom pokretanju algoritama klasterovanja.

U projektu su jasno razdvojeni početni podaci, preprocesirani podaci i skupovi koji se direktno koriste za klasterovanje. Početni podaci se nalaze u direktorijumu *data/raw/*, preprocesirani skup u *data/preprocessed/*, dok se skalirani i redukovani skupovi nalaze u *data/reduced/*.

Ovakva organizacija olakšava ponavljanje eksperimenata i čini strukturu projekta preglednijom. Preprocesiranje predstavlja osnovu za sve naredne faze rada, jer obezbeđuje da svi algoritmi klasterovanja rade nad istim, konzistentno pripremljenim podacima.

5. Redukcija dimenzionalnosti

5.1. Motivacija za redukciju dimenzionalnosti

Nakon preprocesiranja i skaliranja podataka, formiran je skup numeričkih atributa pogodan za primenu algoritama klasterovanja. Međutim, rad sa višedimenzionalnim podacima može predstavljati problem za pojedine algoritme, posebno za one koji se oslanjaju na udaljenosti između instanci.

U prostorima velike dimenzionalnosti pojam udaljenosti može postati manje informativan. Instance mogu delovati međusobno podjednako udaljeno, što otežava formiranje jasno razdvojenih klastera. Ovaj problem je poznat kao prokletstvo dimenzionalnosti. Pored toga, neki atributi mogu nositi slične ili redundantne informacije, pa nije uvek neophodno zadržati sve originalne dimenzije.

Zbog toga je u radu primenjena redukcija dimenzionalnosti pomoću PCA metode. Cilj redukcije nije bio samo smanjenje broja atributa, već i formiranje alternativne reprezentacije podataka nad kojom se mogu testirati algoritmi klasterovanja. Na taj način moguće je uporediti rezultate dobijene nad skaliranim skupom atributa i nad PCA redukovanim skupom atributa.

Redukcija dimenzionalnosti ima i dodatnu praktičnu vrednost: omogućava vizuelizaciju podataka u dvodimenzionalnom prostoru. Pošto se originalni višedimenzionalni podaci ne mogu direktno prikazati, projekcija na prve dve glavne komponente omogućava početni uvid u to da li postoje vidljive grupe ili preklapanja između kategorija.

5.2. PCA metoda

PCA, odnosno Principal Component Analysis, predstavlja jednu od najčešće korišćenih metoda za redukciju dimenzionalnosti. Osnovna ideja PCA metode je da se originalni atributi transformišu u novi skup atributa, koji se nazivaju glavne komponente. Glavne komponente su linearne kombinacije originalnih atributa i uređene su tako da prve komponente objašnjavaju najveći deo varijanse u podacima.

Drugim rečima, PCA pronalazi pravce u prostoru u kojima se podaci najviše razlikuju. Prva glavna komponenta predstavlja pravac najveće varijanse, druga glavna komponenta predstavlja sledeći najvažniji pravac koji je ortogonalan na prvi, i tako dalje. Zadržavanjem samo dela glavnih komponenti moguće je smanjiti dimenzionalnost podataka uz očuvanje značajnog dela njihove strukture.

Pre primene PCA metode važno je da podaci budu skalirani. Razlog je to što PCA zavisi od varijanse atributa. Ako atributi nisu na istoj skali, atributi sa većim numeričkim opsegom mogli bi imati dominantan

uticaj na formiranje glavnih komponenti. Zbog toga se PCA u ovom radu primenjuje nakon skaliranja podataka.

U kontekstu ovog rada PCA ima dve uloge. Prva je formiranje redukovanog skupa atributa koji se koristi za poređenje sa skaliranim skupom. Druga je omogućavanje 2D vizuelizacije, kojom se može steći intuitivan uvid u raspored instanci i potencijalnu separaciju kategorija izraza lica.

5.3. Formiranje skaliranog i PCA skupa podataka

U eksperimentima su korišćene dve verzije podataka. Prva verzija je skalirani skup atributa, označen kao Scaled dataset. Ovaj skup sadrži numeričke attribute nakon skaliranja i predstavlja osnovnu reprezentaciju podataka za klasterovanje.


Druga verzija je PCA dataset, odnosno skup dobijen primenom PCA transformacije nad skaliranim podacima. Ovaj skup predstavlja redukovanu reprezentaciju podataka u prostoru glavnih komponenti. Njegova uloga je da omogući ispitivanje uticaja redukcije dimenzionalnosti na rezultate klasterovanja.

Oba skupa korišćena su za sve algoritme klasterovanja. To znači da su KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i GMM primenjeni i nad skaliranim i nad PCA redukovanim podacima. Ovakav pristup omogućava fer poređenje, jer se za svaki algoritam može analizirati kako se ponaša u originalnom obrađenom prostoru atributa i u redukovanom PCA prostoru.

Skalirani skup podataka sačuvan je kao *X_scaled.npy*, dok je PCA redukovani skup sačuvan kao *X_pca.npy*. Ovi fajlovi predstavljaju ulazne skupove za algoritme klasterovanja u nastavku rada.

5.4. Vizuelizacija podataka u 2D prostoru

Vizuelizacija podataka u 2D prostoru korišćena je kao pomoćni alat za početno razumevanje strukture skupa podataka. Pošto su originalni podaci višedimenzionalni, nije moguće direktno prikazati njihov raspored. PCA projekcija na prve dve glavne komponente omogućava da se svaka instanca predstavi kao tačka u ravni.



Slika 1. PCA projekcija skupa podataka u 2D prostoru prema stvarnim kategorijama izraza.

Ovakav prikaz može pomoći da se uoči da li postoje jasno odvojene grupe, da li su kategorije međusobno pomešane ili da li postoje tačke koje odstupaju od glavne mase podataka. Ipak, važno je naglasiti da 2D vizuelizacija ne prikazuje celu strukturu podataka, već samo projekciju na dve dimenzije. Zbog toga se zaključci ne donose samo na osnovu slike, već se koriste i numeričke metrike.

U ovom radu 2D vizuelizacije ukazuju da kategorije izraza lica nisu potpuno jasno razdvojene. Postoji značajno preklapanje između pojedinih kategorija, što sugeriše da klasterovanje neće nužno proizvesti grupe koje se savršeno poklapaju sa stvarnim oznakama izraza.

Ova činjenica je važna za tumačenje kasnijih rezultata. Ako su kategorije već u početnoj projekciji međusobno pomešane, očekivano je da eksterne metrike kao što su ARI i NMI ne budu visoke. Sa druge strane, algoritmi mogu i dalje pronaći geometrijski smislene klustere koji imaju dobar Silhouette score ili Davies-Bouldin indeks, iako se ti klasteri ne poklapaju potpuno sa stvarnim kategorijama.

6. Algoritmi klasterovanja

U ovom radu primenjeno je pet algoritama klasterovanja: KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i Gaussian Mixture Models. Izbor više različitih algoritama omogućava poređenje pristupa koji polaze od različitih pretpostavki o strukturi podataka. Neki algoritmi pretpostavljaju kompaktne i približno sferne klustere, drugi traže regione povećane gustine, dok treći modeluju podatke pomoću verovatnosnih raspodela ili hijerarhijskih struktura.

Svi algoritmi primenjeni su nad dve verzije skupa podataka: skaliranim skupom atributa i PCA redukovanim skupom atributa. Na taj način je omogućeno poređenje ne samo između algoritama, već i između različitih reprezentacija podataka.

6.1. KMeans

6.1.1. Opis algoritma


KMeans predstavlja jedan od najpoznatijih algoritama klasterovanja. Njegova osnovna ideja je podela podataka na unapred zadat broj klastera tako da instance unutar istog klastera budu što sličnije, a instance iz različitih klastera što različitije. Algoritam funkcioniše tako što za svaki klaster određuje centroid, odnosno reprezentativnu centralnu tačku, a zatim iterativno dodeljuje instance najbližem centroidu i ažurira položaj centroida.

KMeans je posebno pogodan kada se očekuju relativno kompaktni i dobro razdvojeni klasteri. Pošto se oslanja na rastojanja između instanci i centroida, algoritam je osetljiv na skalu atributa, zbog čega se u ovom radu primenjuje nad prethodno skaliranim podacima. Takođe, broj klastera mora biti unapred određen, pa je izbor odgovarajuće vrednosti parametra k jedan od ključnih koraka.

6.1.2. Izbor broja klastera

Za izbor broja klastera kod KMeans algoritma korišćena je Elbow metoda. Ova metoda analizira promenu vrednosti inercije u zavisnosti od broja klastera. Inercija meri ukupnu sumu kvadratnih rastojanja instanci od centroida njihovih klastera, pa se njenim smanjenjem procenjuje koliko dodatni klasteri poboljšavaju model.

U radu je posmatran opseg vrednosti k od 2 do 14. Nakon izračunavanja inercije za svaku vrednost k , analizirana je promena krive kako bi se pronašla tačka nakon koje dodatno povećanje broja klastera ne donosi značajno poboljšanje. Na osnovu tog postupka odabran je broj klastera koji je korišćen u daljoj analizi.



Slika 2. Elbow metoda za izbor broja klastera kod KMeans algoritma za skalirani i PCA skup podataka.

6.1.3. Implementacija i parametri

KMeans je implementiran korišćenjem biblioteke scikit-learn. Algoritam je pokrenut nad skaliranim i PCA redukovanim skupom podataka, pri čemu je za oba skupa kao optimalna vrednost izabrano $k = 4$. Radi stabilnijeg dobijanja rezultata korišćena je višestruka inicijalizacija centroida, sa parametrom $n_init = 10$.

Rezultati KMeans algoritma kasnije su evaluirani pomoću internih i eksternih metrika, a dodatno su prikazane i vizuelizacije rasporeda klastera i kontingencione tabele koje prikazuju odnos između dobijenih klastera i stvarnih kategorija izraza lica.

6.2. DBSCAN

6.2.1. Opis algoritma

DBSCAN je algoritam klasterovanja zasnovan na gustini. Za razliku od KMeans algoritma, DBSCAN ne zahteva unapred zadat broj klastera, već klaster definiše kao regione u kojima postoji dovoljno velika gustina instanci. Osnovna prednost ovog pristupa je to što DBSCAN može pronalaziti klaster proizvoljnog oblika i istovremeno identifikovati instance koje ne pripadaju nijednom klasteru, odnosno šum.

Algoritam koristi dva ključna parametra: eps , koji određuje radijus susedstva, i $min_samples$, koji određuje minimalan broj instanci potreban da bi neka tačka bila jezgro klastera. Na osnovu ovih parametara instance se dele na jezgrene tačke, granične tačke i šum.

6.2.2. Izbor parametara

Izbor parametara kod DBSCAN algoritma ima veliki uticaj na konačan rezultat. Premala vrednost parametra eps može dovesti do toga da veliki broj instanci bude označen kao šum, dok prevelika vrednost može spojiti više različitih grupa u jedan klaster. Slično tome, vrednost parametra $min_samples$ utiče na strogoću uslova za formiranje klastera.

U ovom radu parametri su birani pretragom mreže različitih kombinacija vrednosti *eps* i *min_samples*. Za svaku kombinaciju izračunate su relevantne metrike, a kao glavni kriterijum za izbor korišćen je selection score definisan kao:

$$\text{Selection_score} = \text{Silhouette_non_noise} - \text{Noise_ratio}$$

Ovaj kriterijum je odabran zato što istovremeno nagrađuje dobro razdvojene klastere među tačkama koje nisu šum i penalizuje velika izdvajanja instanci kao šuma. Na taj način je postignut balans između kvaliteta klasterovanja i količine odbačenih instanci.

6.2.3. Implementacija i obrada šuma

DBSCAN je implementiran korišćenjem biblioteke *scikit-learn*. Algoritam je primenjen nad oba skupa podataka, a za svaki skup odabrana je kombinacija parametara koja daje najbolju vrednost *selection score-a*. Za skalirani skup podataka odabrani su parametri *eps* = 3.5 i *min_samples* = 30, dok su za PCA skup podataka odabrani parametri *eps* = 3.0 i *min_samples* = 30.

Pošto DBSCAN može označiti deo instanci kao šum, interne metrike Silhouette i Davies-Bouldin računane su samo nad instancama koje nisu označene kao šum. Pored toga, posebno su analizirani broj klastera, broj noise tačaka i noise ratio, kako bi se dobila potpunija slika ponašanja algoritma.

6.3. HDBSCAN

6.3.1. Opis algoritma

HDBSCAN predstavlja proširenje DBSCAN algoritma. I on pripada algoritmima zasnovanim na gustini, ali za razliku od DBSCAN-a bolje se nosi sa podacima koji sadrže klastere različite gustine. Umesto da koristi jednu fiksnu vrednost parametra *eps* za ceo skup podataka, HDBSCAN gradi hijerarhijsku strukturu zasnovanu na gustini i iz nje izdvaja stabilne klastere.

Zahvaljujući takvom pristupu, HDBSCAN često daje robusnije rezultate od DBSCAN-a kada podaci nisu ravnomerno raspoređeni. Kao i DBSCAN, i HDBSCAN ima mogućnost da deo instanci označi kao šum.

6.3.2. Izbor parametara

Najvažniji parametri HDBSCAN algoritma su *min_cluster_size* i *min_samples*. Parametar *min_cluster_size* određuje minimalnu veličinu klastera, dok *min_samples* utiče na to koliko strogo algoritam procenjuje gustinu potrebnu za formiranje klastera.

U ovom radu parametri su birani pretragom više kombinacija vrednosti, pri čemu je i kod ovog algoritma korišćen selection score kao glavni kriterijum izbora. Time je zadržana ista metodološka logika kao kod DBSCAN algoritma: traži se model koji daje dobru strukturu klastera, ali pritom ne označava prevelik broj instanci kao šum.

6.3.3. Implementacija i prednosti u odnosu na DBSCAN

HDBSCAN je implementiran pomoću biblioteke *hdbscan*. Algoritam je primenjen nad oba skupa podataka, a najbolji rezultati dobijeni su za parametre *min_cluster_size* = 200 i *min_samples* = 20, kako za skalirani, tako i za PCA skup podataka.

U odnosu na DBSCAN, HDBSCAN ima prednost u tome što bolje obrađuje podatke sa neujednačenom gustinom i ne zahteva ručno biranje jednog globalnog parametra *eps*. Ipak, i kod njega je potrebno pažljivo analizirati odnos između kvaliteta klastera i broja instanci označenih kao šum. Zbog toga su, kao i kod DBSCAN algoritma, posebnu ulogu imali noise ratio i selection score.

6.4. Aglomerativno hijerarhijsko klasterovanje

6.4.1. Opis algoritma

Aglomerativno hijerarhijsko klasterovanje predstavlja pristup u kome se polazi od toga da svaka instanca na početku čini zaseban klaster, a zatim se klasteri postepeno spajaju dok se ne dobije željeni broj grupa ili kompletna hijerarhijska struktura. Ovakav pristup omogućava uvid u to kako se klasteri formiraju i spajaju na različitim nivoima.

Jedna od glavnih prednosti ovog algoritma jeste mogućnost vizuelnog prikaza pomoću dendrograma. Dendrogram prikazuje redosled i nivoe spajanja klastera, što može pomoći u interpretaciji strukture podataka i u proceni odgovarajućeg broja klastera.


6.4.2. Izbor broja klastera

Kod aglomerativnog klasterovanja broj klastera je potrebno zadati ili proceniti na osnovu strukture podataka. U ovom radu analizirano je više mogućih vrednosti broja klastera, a kao kriterijum izbora korišćen je Silhouette score. Cilj je bio da se pronađe broj klastera koji daje najbolju unutrašnju strukturu grupisanja.

Na osnovu ovakve analize, za oba skupa podataka kao najbolja vrednost izdvojeno je $k = 2$. Ovaj rezultat ukazuje da hijerarhijska struktura podataka, posmatrana kroz Silhouette meru, favorizuje grublju podelu na manji broj grupa.

6.4.3. Dendrogram i interpretacija hijerarhijske strukture

Pored numeričke evaluacije, kod ovog algoritma važnu ulogu ima i dendrogram. Dendrogram omogućava vizuelni prikaz procesa spajanja instanci i klastera, pa se na osnovu njega može intuitivno proceniti koliko je struktura podataka hijerarhijski izražena.



Slika 3. Dendrogram aglomerativnog hijerarhijskog klasterovanja nad PCA skupom podataka.

U ovom radu dendrogram je korišćen kao pomoć pri interpretaciji rezultata, dok je konačan izbor broja klastera izvršen na osnovu Silhouette score-a. Time je kombinovan kvalitativni i kvantitativni pristup: dendrogram pruža vizuelni uvid, a numerička metrika omogućava objektivniji izbor modela.

6.5. Gaussian Mixture Models

6.5.1. Opis algoritma


Gaussian Mixture Models predstavljaju verovatnosni pristup klasterovanju. Osnovna pretpostavka je da podaci potiču iz mešavine više Gausovih raspodela, pri čemu svaka komponenta odgovara jednom klasteru. Za razliku od KMeans algoritma, koji svakoj instanci dodeljuje tačno jedan klaster, GMM omogućava meku pripadnost, odnosno procenu verovatnoće da instanca pripada svakoj od komponenti.

Ovakav pristup je fleksibilniji, jer može bolje opisivati složenije oblike raspodele podataka. Međutim, kao i kod KMeans algoritma, broj komponenti mora biti određen unapred.

6.5.2. Izbor broja komponenti pomoću BIC kriterijuma

Za izbor broja komponenti kod GMM algoritma korišćen je BIC kriterijum. BIC, odnosno *Bayesian Information Criterion*, predstavlja meru koja uzima u obzir i kvalitet prilagođavanja modela i njegovu složenost. Manja vrednost BIC kriterijuma ukazuje na povoljniji odnos između tačnosti i kompleksnosti modela.

U radu su analizirane vrednosti broja komponenti u određenom opsegu, a za svaku konfiguraciju izračunate su BIC i AIC vrednosti. Kao konačna konfiguracija izabrana je ona koja minimizuje BIC kriterijum, jer taj pristup omogućava sistematičan i objektivan izbor modela.



Slika 4. BIC i AIC vrednosti za različit broj komponenti kod GMM algoritma.

6.5.3. Implementacija i parametri

GMM je implementiran korišćenjem klase `GaussianMixture` iz biblioteke *scikit-learn*. U ovom radu ispitivane su različite vrednosti broja komponenti, pri čemu je kao najpovoljnija konfiguracija za oba skupa podataka izabran model sa 14 komponenti i dijagonalnom kovarijacionom matricom.

Pored BIC i AIC kriterijuma, dobijeni klasteri su naknadno evaluirani i pomoću internih i eksternih metrika, kako bi se GMM mogao porediti sa ostalim algoritmima u radu. Time je obezbeđeno da se ovaj verovatnosni pristup analizira u istom evaluacionom okviru kao i ostali modeli klasterovanja.

7. Evaluacione metrike

Evaluacija rezultata klasterovanja nije jednostavna kao kod klasifikacije, jer algoritmi klasterovanja tokom rada nemaju unapred poznate tačne oznake klasa. Zbog toga se kvalitet klasterovanja može posmatrati iz dva ugla.

Prvi ugao čine interne metrike. One ocenjuju kvalitet klastera na osnovu same geometrijske strukture podataka, bez korišćenja stvarnih oznaka. Takve metrike odgovaraju nenadgledanoj prirodi problema, jer mere koliko su klasteri kompaktni i međusobno razdvojeni.

Drugi ugao čine eksterne metrike. One poredе dobijene klastere sa stvarnim oznakama kategorija. U ovom radu stvarne oznake nisu korišćene tokom klasterovanja, ali su korišćene naknadno, da bi se procenilo koliko se dobijeni klasteri poklapaju sa poznatim gramatičkim kategorijama izraza lica.

Pored ovih metrika, za pojedine algoritme korišćene su i dodatne mere. Kod DBSCAN i HDBSCAN algoritama analizirani su noise ratio i selection score, jer ovi algoritmi mogu deo instanci označiti kao šum. Kod GMM algoritma korišćeni su BIC i AIC kriterijumi za izbor broja komponenti modela.

7.1. Silhouette score

Silhouette score je interna metrika koja meri koliko je svaka instanca dobro uklopljena u svoj klaster u odnosu na najbliži drugi klaster. Ova metrika istovremeno uzima u obzir kompaktnost klastera i razdvojenost između klastera.

Za jednu instancu posmatraju se dve vrednosti. Prva je prosečna udaljenost te instance od ostalih instanci u istom klasteru. Druga je prosečna udaljenost od instanci iz najbližeg drugog klastera. Ako je instanca bliža tačkama iz svog klastera nego tačkama iz drugih klastera, Silhouette vrednost će biti veća.

Silhouette score ima vrednosti u intervalu od -1 do 1. Vrednosti bliske 1 ukazuju na dobro formirane klastere, vrednosti oko 0 znače da se instance nalaze blizu granice između klastera, dok negativne vrednosti ukazuju da su neke instance verovatno dodeljene pogrešnom klasteru.

U ovom radu Silhouette score je korišćen kao jedna od glavnih internih metrika za procenu kvaliteta klasterovanja. Veća vrednost ove metrike tumači se kao bolji rezultat. Kod DBSCAN i HDBSCAN algoritama Silhouette score je računat samo nad instancama koje nisu označene kao šum, jer šum ne predstavlja regularan klaster.

7.2. Davies-Bouldin indeks

Davies-Bouldin indeks je interna metrika koja meri prosečnu sličnost svakog klastera sa njemu najbližim drugim klasterom. Ideja ove metrike je da dobar skup klastera treba da ima male razlike unutar klastera i velike razlike između klastera.

Za svaki klaster posmatra se njegova rasutost, odnosno koliko su instance udaljene od centra klastera. Zatim se ta rasutost poredi sa udaljenošću do drugih klastera. Ako su klasteri kompaktni i međusobno udaljeni, Davies-Bouldin indeks će imati manju vrednost.

Za razliku od Silhouette score-a, kod Davies-Bouldin indeksa manje vrednosti predstavljaju bolji rezultat. Vrednosti bliže nuli ukazuju na kompaktnije i bolje razdvojene klastere, dok veće vrednosti ukazuju na slabiju separaciju ili veću rasutost unutar klastera.

U ovom radu Davies-Bouldin indeks korišćen je kao dopuna Silhouette meri. Kombinovanjem ove dve metrike dobija se pouzdaniji uvid u unutrašnju strukturu klastera, jer se kvalitet ne posmatra samo iz jednog ugla.

7.3. Adjusted Rand Index

Adjusted Rand Index, skraćeno ARI, predstavlja eksternu metriku za poređenje dobijenih klastera sa stvarnim oznakama klasa. Ova metrika meri koliko se parovi instanci dosledno nalaze zajedno ili odvojeno u dobijenim klasterima i u stvarnim klasama.

Ako dve instance pripadaju istoj stvarnoj kategoriji i algoritam ih smesti u isti klaster, to se računa kao slaganje. Takođe, ako dve instance pripadaju različitim stvarnim kategorijama i algoritam ih smesti u različite klastere, i to se računa kao slaganje. ARI zatim koriguje rezultat za slučajno poklapanje, što ga čini pouzdanijim od običnog Rand indeksa.

Vrednost ARI metrike najčešće se tumači tako da vrednost 1 označava savršeno poklapanje između klastera i stvarnih klasa, vrednost bliska 0 označava poklapanje slično slučajnom, dok negativne vrednosti mogu ukazivati na lošije poklapanje od slučajnog.

U ovom radu ARI nije korišćen za izbor parametara algoritama, jer bi to značilo korišćenje stvarnih oznaka u procesu izbora modela. Umesto toga, korišćen je isključivo za naknadnu evaluaciju, kako bi se proverilo koliko se klasteri poklapaju sa gramatičkim kategorijama izraza lica.

7.4. Normalized Mutual Information

Normalized Mutual Information, skraćeno NMI, predstavlja eksternu metriku koja meri količinu zajedničke informacije između dobijenih klastera i stvarnih oznaka klasa. Drugim rečima, ova metrika meri koliko poznavanje klastera smanjuje neizvesnost o stvarnoj kategoriji i obrnuto.

NMI ima vrednosti u intervalu od 0 do 1. Vrednost 1 označava potpuno poklapanje između klastera i stvarnih kategorija, dok vrednost 0 označava da između njih nema korisne zajedničke informacije.

Prednost NMI metrike je u tome što je pogodna za poređenje klasterovanja kada broj klastera ne mora biti jednak broju stvarnih klasa. To je važno u ovom radu, jer neki algoritmi mogu pronaći manji ili veći broj klastera od broja stvarnih kategorija izraza lica. Na primer, DBSCAN i HDBSCAN sami određuju broj klastera na osnovu gustine podataka, dok KMeans i AHC koriste unapred izabran broj klastera.

Kao i ARI, NMI je korišćen samo za naknadnu evaluaciju rezultata. Ova metrika pomaže da se proceni da li dobijeni klasteri nose informaciju o stvarnim gramatičkim kategorijama, čak i kada poklapanje nije savršeno.

7.5. Noise ratio i Selection score

DBSCAN i HDBSCAN se razlikuju od ostalih algoritama korišćenih u radu po tome što ne moraju svaku instancu dodeliti nekom klasteru. Instance koje se ne nalaze u dovoljno gustim regionima prostora mogu biti označene kao šum. Zbog toga za ove algoritme nije dovoljno posmatrati samo Silhouette score ili Davies-Bouldin indeks.

Noise ratio predstavlja odnos broja instanci označenih kao šum i ukupnog broja instanci u skupu podataka. Veći noise ratio znači da algoritam odbacuje veći deo podataka kao šum. To može biti korisno ako zaista postoje autlajeri, ali može biti problem ako algoritam previše instanci izostavi iz klasterovanja.

Kod gustinskih algoritama može se desiti da se dobije visok Silhouette score samo zato što je algoritam zadržao mali broj vrlo kompaktnih klastera, dok je veliki deo podataka označio kao šum. Takav rezultat ne mora biti praktično koristan, jer model ne objašnjava većinu podataka. Zbog toga je u ovom radu uveden selection score.

Selection score je definisan kao razlika između Silhouette score-a računatog nad tačkama koje nisu šum i noise ratio vrednosti:

$$\text{Selection_score} = \text{Silhouette_non_noise} - \text{Noise_ratio}$$

Ovaj kriterijum nagrađuje modele koji formiraju kvalitetne klasterove, ali istovremeno kažnjava modele koji preveliki deo podataka označavaju kao šum. Na taj način se dobija uravnoteženija mera za izbor parametara kod DBSCAN i HDBSCAN algoritama.

7.6. BIC i AIC za GMM

Kod Gaussian Mixture Models algoritma potrebno je odrediti broj komponenti, odnosno broj Gausovih raspodela koje čine mešavinu. Veći broj komponenti može bolje opisati podatke, ali istovremeno povećava složenost modela i rizik od preteranog prilagođavanja podacima.

Za izbor broja komponenti korišćeni su BIC i AIC kriterijumi. BIC, odnosno Bayesian Information Criterion, i AIC, odnosno Akaike Information Criterion, predstavljaju mere koje kombinuju kvalitet prilagođavanja modela i kaznu za složenost modela. Kod obe metrike manje vrednosti ukazuju na bolji odnos između kvaliteta modela i njegove kompleksnosti. AIC obično blaže kažnjava složenije modele, dok BIC uvodi strožu kaznu za veći broj parametara. Zbog toga se BIC često koristi kada je cilj izbor jednostavnijeg modela koji i dalje dobro opisuje podatke.

U ovom radu BIC je korišćen kao glavni kriterijum za izbor broja komponenti kod GMM algoritma. AIC je dodatno prikazan radi poređenja i boljeg uvida u ponašanje modela pri različitom broju komponenti. Nakon izbora broja komponenti, dobijeni GMM modeli su evaluirani istim metrikama kao i ostali algoritmi, kako bi se omogućilo zajedničko poređenje rezultata.

8. Analiza rezultata

U ovom poglavlju prikazani su rezultati pojedinačnih algoritama klasterovanja. Svaki algoritam analiziran je nad dve verzije skupa podataka: skaliranim skupom atributa i PCA redukovanim skupom atributa. Cilj ove analize nije samo da se pronađe algoritam sa najboljom vrednošću jedne metrike, već da se razume ponašanje svakog algoritma u odnosu na korišćenu reprezentaciju podataka.

Za svaku metodu posmatrane su interne metrike, koje mere geometrijski kvalitet klastera, kao i eksterne metrike, koje porede dobijene klasterove sa stvarnim kategorijama izraza lica. Kod DBSCAN i HDBSCAN algoritama dodatno je analiziran odnos instanci označenih kao šum, dok su kod GMM algoritma posmatrani i BIC/AIC kriterijumi.

8.1. Rezultati KMeans algoritma

KMeans algoritam je primenjen nad skaliranim i PCA redukovanim skupom podataka. Za oba skupa podataka izabran je broj klastera $k = 4$, na osnovu Elbow metode. Algoritam svaku instancu dodeljuje jednom klasteru, pa kod ovog algoritma nema instanci označenih kao šum.

Skup podataka	Broj klastera	Silhouette	Davies-Bouldin	ARI	NMI
Scaled dataset	4	0.2807	1.5513	0.0577	0.1389
PCA dataset	4	0.2987	1.4640	0.0577	0.1388

Tabela 2. Rezultati KMeans algoritma

Rezultati pokazuju da KMeans daje nešto bolje interne metrike nad PCA skupom podataka. Silhouette score je veći za PCA dataset, dok je Davies-Bouldin indeks manji, što ukazuje na bolju unutrašnju strukturu klastera nakon redukcije dimenzionalnosti. Razlika nije velika, ali sugeriše da je PCA reprezentacija pomogla da se klasteri učine kompaktnijim i bolje razdvojenim.

Sa druge strane, ARI i NMI vrednosti su veoma slične za oba skupa podataka. To znači da promena reprezentacije podataka nije značajno promenila poklapanje dobijenih klastera sa stvarnim kategorijama izraza lica. Iako KMeans pronalazi određenu geometrijsku strukturu, dobijeni klasteri se samo delimično poklapaju sa originalnim oznakama.

Ovakav rezultat je očekivan za KMeans, jer algoritam favorizuje kompaktne i približno sferne klastere. Ako stvarne kategorije izraza lica nisu raspoređene u takvim grupama, KMeans može dati relativno stabilne klastere, ali bez jakog semantičkog poklapanja sa pravim klasama.

8.2. Rezultati DBSCAN algoritma

DBSCAN je algoritam zasnovan na gustini i razlikuje se od KMeans algoritma po tome što ne zahteva unapred zadat broj klastera. Umesto toga, broj klastera nastaje iz strukture gustine u podacima. Pored toga, DBSCAN može deo instanci označiti kao šum.

Za izbor parametara korišćen je selection score, koji predstavlja razliku između Silhouette score-a nad instancama koje nisu šum i noise ratio vrednosti. Time se uzima u obzir i kvalitet formiranih klastera i procenat instanci koje algoritam izostavlja kao šum.

Skup podataka	eps	min_samples	Broj klastera	Noise ratio	Silhouette	Davies-Bouldin	ARI	NMI	Selection score
Scaled dataset	3.5	30	11	0.4522	0.2201	1.1712	0.0274	0.0958	-0.2321
PCA dataset	3.0	30	10	0.4463	0.2055	0.9490	0.0267	0.0938	-0.2408

Tabela 3. Rezultati DBSCAN algoritma

Rezultati pokazuju da DBSCAN pronalazi 11 klastera nad skaliranim skupom i 10 klastera nad PCA skupom. Međutim, u oba slučaja veliki deo instanci označen je kao šum. Noise ratio iznosi približno 45% za skalirani skup i približno 44% za PCA skup. To znači da algoritam ne uspeva da uključi značajan deo podataka u regularne klastere.

Silhouette score, računat samo nad instancama koje nisu šum, ima umerene vrednosti. Davies-Bouldin indeks je bolji kod PCA skupa, što ukazuje da su ne-šum klasteri u PCA prostoru bolje razdvojeni. Ipak, selection score je negativan u oba slučaja, jer noise ratio značajno umanjuje ukupnu ocenu modela.

ARI i NMI vrednosti su niske, što pokazuje da se DBSCAN klasteri slabo poklapaju sa stvarnim kategorijama izraza lica. To ne znači nužno da algoritam nije pronašao nikakvu strukturu, već da struktura zasnovana na gustini ne odgovara dobro originalnim gramatičkim oznakama.

DBSCAN je u ovom radu koristan jer pokazuje da u podacima postoje određene guste oblasti, ali istovremeno ukazuje i na to da veliki deo podataka ne pripada jasno definisanim gustinskim klasterima.

8.3. Rezultati HDBSCAN algoritma

HDBSCAN je takođe algoritam zasnovan na gustini, ali je fleksibilniji od DBSCAN-a jer može bolje raditi sa klasterima različite gustine. Umesto korišćenja jedne globalne vrednosti eps, HDBSCAN gradi hijerarhijsku strukturu gustine i izdvaja stabilne klastere.

Skup podataka	min_cluster_size	min_samples	Broj klastera	Noise ratio	Silhouette	Davies-Bouldin	ARI	NMI	Selection score
Scaled dataset	200	20	5	0.3458	0.2721	1.3551	0.0268	0.0673	-0.0737
PCA dataset	200	20	3	0.3272	0.3958	0.7061	0.0221	0.0517	0.0686

Tabela 4. Rezultati HDBSCAN algoritma

U poređenju sa DBSCAN algoritmom, HDBSCAN označava manji deo podataka kao šum. Noise ratio iznosi približno 35% za skalirani skup i 33% za PCA skup. To znači da HDBSCAN uspeva da uključi veći deo instanci u klastere, dok i dalje zadržava mogućnost identifikacije šuma.

Najbolji interni rezultat HDBSCAN daje nad PCA skupom podataka. Silhouette score je znatno veći nego kod skaliranog skupa, a Davies-Bouldin indeks je značajno manji. To ukazuje da su klasteri u PCA prostoru kompaktniji i bolje razdvojeni. Selection score je veći za PCA skup podataka. Kod skaliranog skupa ova vrednost je blago negativna, dok je kod PCA skupa pozitivna, što pokazuje da PCA reprezentacija daje povoljniji balans između kvaliteta klastera i količine šuma.

Ipak, ARI i NMI vrednosti ostaju niske. To znači da se klasteri koje HDBSCAN pronalazi ne poklapaju značajno sa stvarnim gramatičkim kategorijama izraza lica. HDBSCAN je, međutim, u odnosu na DBSCAN dao stabilnije rezultate, manji procenat šuma i bolju internu strukturu klastera, posebno nad PCA skupom.

8.4. Rezultati aglomerativnog hijerarhijskog klasterovanja

Aglomerativno hijerarhijsko klasterovanje primenjeno je nad oba skupa podataka, a izbor broja klastera izvršen je na osnovu Silhouette score-a. Za oba skupa kao najbolja vrednost izdvojeno je $k = 2$, što ukazuje da ovaj algoritam, prema internoj metrici, favorizuje grublju podelu podataka.

Skup podataka	Broj klastera	Silhouette	Davies-Bouldin	ARI	NMI
Scaled dataset	2	0.4827	0.8263	0.0047	0.0093
PCA dataset	2	0.4949	0.8028	0.0028	0.0056

Tabela 5. Rezultati aglomerativnog hijerarhijskog klasterovanja

Ovaj algoritam daje najbolje interne metrike među analiziranim metodama u pojedinačnoj analizi. Silhouette score je visok u poređenju sa ostalim algoritmima, a Davies-Bouldin indeks je nizak, što ukazuje na dobru unutrašnju separaciju dva klastera. PCA skup daje nešto bolji Silhouette score i nešto niži Davies-Bouldin indeks, pa je unutrašnja struktura klastera blago bolja u PCA prostoru.

Međutim, ARI i NMI vrednosti su vrlo niske. To znači da iako algoritam pronalazi dve dobro razdvojene grupe, te grupe se gotovo ne poklapaju sa stvarnim kategorijama izraza lica. Drugim rečima, aglomerativno klasterovanje pronalazi geometrijski jasnu, ali semantički slabo usklađenu podelu.

Ovaj rezultat je važan jer pokazuje razliku između internih i eksternih metrika. Dobar Silhouette score ne znači nužno da su klasteri u skladu sa pravim klasama. U ovom slučaju algoritam uspešno deli podatke na dve grupe, ali stvarnih kategorija ima više i one nisu jasno razdvojene takvom binarnom podelom.

8.5. Rezultati GMM algoritma

Gaussian Mixture Models primenjen je kao verovatnosni pristup klasterovanju. Za izbor broja komponenti korišćen je BIC kriterijum, a u analiziranom opsegu kao najbolji izbor za oba skupa podataka izdvojeno je 14 komponenti uz dijagonalnu kovarijacionu matricu.

Skup podataka	Broj komponenti	Kov. tip	BIC	AIC	Silhouette	Davies-Bouldin	ARI	NMI
Scaled dataset	14	diag	181159.83	134039.43	0.1297	2.4912	0.0998	0.2195
PCA dataset	14	diag	189987.15	180504.82	-0.0658	3.3168	0.0525	0.1333

Tabela 6. Rezultati GMM algoritma

GMM daje različito ponašanje u odnosu na interne i eksterne metrike. Nad skaliranim skupom podataka dobija se pozitivan Silhouette score, dok je nad PCA skupom Silhouette score negativan. Negativna vrednost ukazuje na to da su pojedine instance verovatno bliže drugim komponentama nego onima kojima su dodeljene. Davies-Bouldin indeks je takođe bolji kod skaliranog skupa, što dodatno ukazuje da je GMM u ovom slučaju bolje radio nad skaliranim nego nad PCA podacima.

Sa druge strane, GMM daje najbolje vrednosti eksternih metrika među posmatranim algoritmima, posebno nad skaliranim skupom podataka. ARI iznosi 0.0998, dok NMI iznosi 0.2195. Iako su ove vrednosti i dalje relativno niske, one su veće nego kod ostalih algoritama. To znači da GMM klasteri imaju nešto bolje poklapanje sa stvarnim kategorijama izraza lica, iako interna struktura klastera nije najbolja.

Ovaj rezultat pokazuje da algoritam koji ima slabije interne metrike može imati bolje poklapanje sa stvarnim oznakama. GMM verovatnosni pristup može uhvatiti određene raspodele koje su povezane sa kategorijama izraza, ali te raspodele nisu nužno jasno razdvojene u geometrijskom smislu.

Na osnovu pojedinačne analize može se zaključiti da GMM ima najbolji odnos prema eksternim metrikama, dok aglomerativno hijerarhijsko klasterovanje i HDBSCAN daju bolje interne rezultate. Konačno poređenje ovih zaključaka dato je u narednom poglavlju.

9. Finalno poređenje algoritama

Nakon pojedinačne analize rezultata, izvršeno je finalno poređenje svih algoritama klasterovanja. Cilj ovog poglavlja je da se objedine rezultati dobijeni različitim metodama i da se utvrdi kako se algoritmi ponašaju prema različitim metrikama.


Važno je naglasiti da kod klasterovanja ne postoji uvek jedan apsolutno najbolji algoritam. Različite metrike mere različite aspekte kvaliteta. Interne metrike, kao što su Silhouette score i Davies-Bouldin indeks, ocenjuju geometrijsku strukturu klastera, dok eksterne metrike, kao što su ARI i NMI, mere poklapanje dobijenih klastera sa stvarnim kategorijama izraza lica.

Zbog toga se u ovom radu rezultati tumače kroz više kriterijuma. Posebno se posmatraju interna separacija klastera, poklapanje sa stvarnim oznakama i ponašanje algoritama koji mogu da označe deo podataka kao šum.

9.1. Poređenje po Silhouette meri

Silhouette score meri koliko su klasteri kompaktni i međusobno razdvojeni. Veće vrednosti ove metrike ukazuju na bolju unutrašnju strukturu klastera.

U finalnom poređenju najbolji rezultat prema Silhouette meri daje aglomerativno hijerarhijsko klasterovanje. Nad PCA skupom podataka ostvarena je vrednost 0.4949, dok je nad skaliranim skupom dobijena vrednost 0.4827. Ovi rezultati su viši od rezultata ostalih algoritama, što ukazuje da aglomerativno klasterovanje pronalazi najjasnije razdvojenu unutrašnju strukturu u podacima.



Slika 5. Poređenje algoritama prema Silhouette meri.


HDBSCAN takođe daje relativno dobar rezultat nad PCA skupom podataka, sa Silhouette vrednošću 0.3958. KMeans ostvaruje umerene vrednosti, pri čemu je rezultat nešto bolji nad PCA skupom nego nad skaliranim skupom. DBSCAN daje niže vrednosti Silhouette mere, dok GMM ima najlošiji rezultat nad PCA skupom, gde je Silhouette vrednost negativna.

Ovi rezultati pokazuju da PCA redukcija kod nekih algoritama poboljšava unutrašnju strukturu klastera. To je posebno vidljivo kod aglomerativnog klasterovanja, KMeans algoritma i HDBSCAN algoritma. Međutim, kod GMM algoritma PCA skup daje slabiji rezultat prema ovoj metrici.

9.2. Poređenje po Davies-Bouldin indeksu

Davies-Bouldin indeks meri odnos između rasutosti unutar klastera i razdvojenosti između klastera. Za razliku od Silhouette mere, kod Davies-Bouldin indeksa manje vrednosti predstavljaju bolji rezultat.

Najbolji rezultat prema Davies-Bouldin indeksu ostvaruje HDBSCAN nad PCA skupom podataka, sa vrednošću 0.7061. Slede aglomerativno hijerarhijsko klasterovanje nad PCA skupom sa vrednošću 0.8028 i nad skaliranim skupom sa vrednošću 0.8263. DBSCAN nad PCA skupom takođe daje relativno povoljan rezultat, sa vrednošću 0.9490.



Slika 6. Poređenje algoritama prema Davies-Bouldin indeksu.


KMeans ostvaruje srednje vrednosti Davies-Bouldin indeksa, dok GMM ima znatno veće vrednosti, posebno nad PCA skupom podataka. To ukazuje da su GMM klasteri, prema internoj geometrijskoj strukturi, manje kompaktni i slabije razdvojeni od klastera dobijenih drugim algoritmima.

Poređenje po ovoj metrici potvrđuje da algoritmi zasnovani na hijerarhijskoj strukturi i gustini mogu dati bolje unutrašnje razdvajanje klastera. Posebno se izdvaja HDBSCAN nad PCA skupom, koji postiže najbolji balans između kompaktnosti klastera i njihove međusobne separacije.

9.3. Poređenje po ARI i NMI metrikama


ARI i NMI predstavljaju eksterne metrike, jer porede dobijene klastere sa stvarnim kategorijama izraza lica. One su posebno važne jer pokazuju da li klasteri koje algoritmi pronalaze odgovaraju poznatim gramatičkim kategorijama.

Prema ARI metrici, najbolji rezultat ostvaruje GMM nad skaliranim skupom podataka, sa vrednošću 0.0998. Slede KMeans nad oba skupa podataka, sa vrednošću 0.0577, i GMM nad PCA skupom, sa vrednošću 0.0525. Ostali algoritmi imaju niže ARI vrednosti.



Slika 7. Poređenje algoritama prema ARI metrici.

Slično se vidi i kod NMI metrike. Najbolji rezultat ostvaruje GMM nad skaliranim skupom podataka, sa vrednošću 0.2195. KMeans ostvaruje NMI vrednosti oko 0.1389, dok GMM nad PCA skupom ima vrednost 0.1333. DBSCAN, HDBSCAN i aglomerativno klasterovanje imaju niže vrednosti NMI metrike.



Slika 8. Poređenje algoritama prema NMI metrici.

Ovi rezultati pokazuju zanimljivu razliku između internih i eksternih metrika. Algoritam koji ima najbolje interne rezultate nije nužno algoritam koji najbolje odgovara stvarnim kategorijama. Aglomerativno klasterovanje ima najbolje Silhouette vrednosti, ali vrlo niske ARI i NMI vrednosti. Sa druge strane, GMM nema najbolje interne metrike, ali ostvaruje najbolje poklapanje sa stvarnim oznakama.


Ova razlika ukazuje da geometrijski jasno razdvojeni klasteri ne moraju odgovarati gramatičkim kategorijama izraza lica. Stvarne kategorije mogu biti raspoređene tako da se međusobno preklapaju u prostoru atributa, pa ih nije lako dobiti samo na osnovu nenadgledanog grupisanja.

9.4. Poređenje gustinskih algoritama prema odnosu šuma

DBSCAN i HDBSCAN se razlikuju od ostalih algoritama jer mogu deo instanci označiti kao šum. Zbog toga je za njih važno posmatrati ne samo kvalitet klastera, već i procenat podataka koji algoritam nije uključio u klustere.

DBSCAN označava približno 45% instanci kao šum nad oba skupa podataka. Noise ratio iznosi 0.4522 za skalirani skup i 0.4463 za PCA skup. Ove vrednosti ukazuju da DBSCAN ne uspeva da veliki deo podataka uključi u regularne klustere.

HDBSCAN daje povoljniji rezultat po ovom kriterijumu. Noise ratio iznosi 0.3458 za skalirani skup i 0.3272 za PCA skup. To znači da HDBSCAN zadržava veći deo podataka unutar klastera, dok i dalje ima mogućnost da izdvoji instance koje odstupaju od glavne strukture.



Slika 9. Poređenje DBSCAN i HDBSCAN algoritama prema odnosu šuma.

Selection score dodatno potvrđuje ovu razliku. Kod DBSCAN algoritma selection score je negativan za oba skupa podataka, jer veliki procenat šuma nadjačava kvalitet klastera nad preostalim instancama. Kod HDBSCAN algoritma selection score je znatno povoljniji nego kod DBSCAN algoritma. Za skalirani skup podataka vrednost je blago negativna, dok je za PCA skup pozitivna. Zbog toga se HDBSCAN pokazuje kao stabilniji gustinski algoritam za ovaj skup podataka, posebno nad PCA reprezentacijom.

9.5. Najbolji algoritmi po skupovima podataka

Kada se rezultati posmatraju po skupovima podataka, vidi se da ne postoji isti algoritam koji dominira prema svim metrikama. Za PCA skup podataka najbolji Silhouette score ostvaruje aglomerativno hijerarhijsko

klasterovanje, dok najbolji Davies-Bouldin indeks daje HDBSCAN. Najbolje ARI i NMI vrednosti nad PCA skupom ostvaruju KMeans i GMM, u zavisnosti od posmatrane metrike.

Za skalirani skup podataka aglomerativno klasterovanje takođe ostvaruje najbolji Silhouette score i najbolji Davies-Bouldin indeks. Međutim, prema eksternim metrikama najbolji rezultat daje GMM. To znači da skalirani skup bolje odgovara GMM modelu kada se posmatra poklapanje sa stvarnim kategorijama, dok aglomerativno klasterovanje bolje opisuje internu geometrijsku strukturu podataka.

Skup podataka	Najbolji Silhouette	Najbolji DB	Najbolji ARI	Najbolji NMI
PCA dataset	AHC (0.4949)	HDBSCAN (0.7061)	KMeans (0.0577)	KMeans (0.1388)
Scaled dataset	AHC (0.4827)	AHC (0.8263)	GMM (0.0998)	GMM (0.2195)

Tabela 7. Najbolji algoritmi po skupovima podataka i metrikama.

Ovakvi rezultati pokazuju da izbor najboljeg algoritma zavisi od cilja analize. Ako je cilj dobiti interno dobro razdvojene klastere, aglomerativno klasterovanje i HDBSCAN daju najbolje rezultate. Ako je cilj dobiti klastere koji se bolje poklapaju sa stvarnim gramatičkim kategorijama, GMM nad skaliranim podacima daje najpovoljniji rezultat.

9.6. Tumačenje finalnih rezultata

Finalno poređenje pokazuje da podaci o gramatičkim izrazima lica nemaju jednostavnu i jasno razdvojenu klustersku strukturu koja se direktno poklapa sa stvarnim kategorijama. To se vidi po relativno niskim vrednostima ARI i NMI metrika kod svih algoritama.

Sa druge strane, interne metrike pokazuju da se u podacima mogu pronaći određene geometrijske strukture. Aglomerativno hijerarhijsko klasterovanje i HDBSCAN uspevaju da formiraju klastere koji su relativno kompaktni i dobro razdvojeni. Međutim, te strukture ne odgovaraju u potpunosti originalnim gramatičkim kategorijama izraza.

Ovaj rezultat je važan jer pokazuje ograničenje nenadgledanog klasterovanja u ovom problemu. Algoritmi mogu pronaći grupe na osnovu numeričke sličnosti instanci, ali te grupe ne moraju biti iste kao semantičke ili gramatičke kategorije koje su definisane u skupu podataka.

Može se zaključiti da je GMM najuspešniji ako se posmatra poklapanje sa stvarnim oznakama, dok su aglomerativno klasterovanje i HDBSCAN uspešniji ako se posmatra unutrašnji kvalitet klastera. KMeans daje stabilne, ali umerene rezultate, dok DBSCAN pokazuje ograničenja zbog velikog broja instanci označenih kao šum.

Ukupno gledano, rezultati ukazuju da su gramatičke kategorije izraza lica delimično prisutne u numeričkom prostoru atributa, ali nisu jasno separabilne metodama klasterovanja. Zbog toga je za precizno prepoznavanje kategorija verovatno pogodniji nadgledani pristup, dok klasterovanje ostaje korisno za istraživanje unutrašnje strukture podataka i otkrivanje potencijalnih grupa.

10. Diskusija

Diskusija rezultata ima za cilj da objasni zašto su pojedini algoritmi dali različite rezultate i šta se iz toga može zaključiti o strukturi podataka. Pošto je u radu korišćeno više algoritama i više metrika, nije

dovoljno samo izdvojiti najveću ili najmanju vrednost pojedinačne metrike. Potrebno je razumeti šta svaka metrika meri i kakvu strukturu podataka favorizuje svaki algoritam.

Rezultati pokazuju da skup podataka o gramatičkim izrazima lica nema jednostavnu klasteršku strukturu koja se direktno poklapa sa stvarnim kategorijama. Neki algoritmi su formirali relativno kompaktne i dobro razdvojene klasterne, ali ti klasteri nisu nužno odgovarali originalnim oznakama izraza. Sa druge strane, algoritmi koji su ostvarili bolje poklapanje sa stvarnim kategorijama nisu uvek imali najbolje interne metrike.

Ovakav ishod je očekivan kod nenadgledanog učenja. Algoritmi klasterovanja ne znaju značenje kategorija, već rade isključivo na osnovu numeričkih odnosa među instancama. Zbog toga mogu pronaći grupe koje su geometrijski smislene, ali nisu iste kao gramatičke kategorije koje su definisane u skupu podataka.

10.1. Uticaj izbora algoritma

Izbor algoritma imao je značajan uticaj na rezultate. KMeans je dao stabilne i umerene rezultate, ali nije ostvario izrazito visoko poklapanje sa stvarnim kategorijama. To je posledica pretpostavke ovog algoritma da klasteri treba da budu kompaktni i raspoređeni oko centroida. Ako stvarne kategorije izraza nemaju takav oblik u prostoru atributa, KMeans ne može potpuno da ih izdvoji.

DBSCAN je pokazao drugačije ponašanje. Kao algoritam zasnovan na gustini, on pokušava da pronađe guste oblasti u prostoru podataka i da instance koje ne pripadaju takvim oblastima označi kao šum. Kod ovog skupa podataka DBSCAN je označio veliki procenat instanci kao šum, što ukazuje da podaci nemaju jednostavnu gustinsku strukturu koja bi odgovarala ovom algoritmu. Iako su neki klasteri pronađeni, veliki odnos šuma smanjuje praktičnu upotrebljivost rezultata.

HDBSCAN je dao stabilnije rezultate od DBSCAN algoritma. Ovaj algoritam je uspeo da smanji procenat šuma i da dobije bolje interne metrike, posebno nad PCA skupom podataka. To pokazuje da je hijerarhijski pristup gustini pogodniji od korišćenja jedne fiksne vrednosti eps parametra. Ipak, ni HDBSCAN nije ostvario visoko poklapanje sa stvarnim kategorijama izraza.

Aglomerativno hijerarhijsko klasterovanje ostvarilo je najbolje interne rezultate, naročito prema Silhouette meri. To znači da je algoritam pronašao jasno razdvojenu strukturu u podacima, ali uglavnom kao grublju podelu na manji broj klastera. Međutim, veoma niske ARI i NMI vrednosti pokazuju da ta podela ne odgovara dobro stvarnim gramatičkim kategorijama. Ovaj rezultat je dobar primer razlike između geometrijskog kvaliteta klastera i semantičkog značenja klastera.

GMM je dao najpovoljnije eksterne metrike, posebno nad skaliranim skupom podataka. To znači da se njegove komponente bolje poklapaju sa stvarnim oznakama u odnosu na ostale algoritme. Međutim, interne metrike kod GMM-a nisu bile najbolje, što ukazuje da klasteri nisu najkompaktniji ni najbolje razdvojeni. Ovaj rezultat sugerise da verovatnosni pristup može uhvatiti određene obrasce povezane sa stvarnim kategorijama, iako te kategorije nisu jasno separabilne u geometrijskom smislu.

10.2. Uticaj PCA redukcije

PCA redukcija dimenzionalnosti imala je različit uticaj na različite algoritme. Kod KMeans algoritma PCA skup je dao nešto bolji Silhouette score i niži Davies-Bouldin indeks, što ukazuje na bolju unutrašnju strukturu klastera. Slično se vidi i kod HDBSCAN algoritma, gde je PCA skup dao bolji odnos između kvaliteta klastera i količine šuma.

Kod aglomerativnog hijerarhijskog klasterovanja PCA skup je takođe dao blago bolje interne rezultate. To pokazuje da je redukcija dimenzionalnosti pomogla da se izdvoji jasnija geometrijska struktura podataka. Moguće objašnjenje je da PCA uklanja deo redundantnih ili manje informativnih dimenzija, pa algoritmi lakše pronalaze osnovne obrasce u podacima.

Sa druge strane, kod GMM algoritma PCA nije dala bolje rezultate. GMM nad skaliranim skupom ostvario je bolje interne i eksterne metrike nego GMM nad PCA skupom. To ukazuje da su informacije koje su korisne za verovatnosno modelovanje možda delimično izgubljene redukcijom dimenzionalnosti. PCA čuva pravce najveće varijanse, ali ti pravci ne moraju nužno biti najkorisniji za razdvajanje stvarnih kategorija.

Ovi rezultati pokazuju da PCA nije univerzalno poboljšanje. Ona može pomoći kod nekih algoritama, posebno onih koji se oslanjaju na udaljenosti i unutrašnju separaciju klastera, ali može pogoršati rezultate kod algoritama kojima su potrebne finije informacije iz originalnog prostora atributa.

10.3. Ograničenja korišćenih metrika

Jedno od važnih ograničenja rada jeste činjenica da različite metrike favorizuju različite aspekte klasterovanja. Silhouette score i Davies-Bouldin indeks ocenjuju geometrijsku strukturu klastera. Ako algoritam pronađe mali broj jasno razdvojenih grupa, ove metrike mogu biti dobre, čak i kada se te grupe ne poklapaju sa stvarnim kategorijama.

To se jasno vidi kod aglomerativnog hijerarhijskog klasterovanja. Ovaj algoritam je ostvario visoke Silhouette vrednosti, ali vrlo niske ARI i NMI vrednosti. Dakle, prema internim metrikama klasteri izgledaju dobro, ali prema eksternim metrikama oni ne odgovaraju stvarnim oznakama izraza.

Sa druge strane, GMM je ostvario najbolje eksterne metrike, iako nije imao najbolje interne rezultate. To pokazuje da poklapanje sa stvarnim kategorijama ne mora zahtevati klastere koji su strogo kompaktni i jasno razdvojeni. Stvarne kategorije mogu biti raspoređene složenije, sa preklapanjima i nejasnim granicama.

Posebno ograničenje postoji kod DBSCAN i HDBSCAN algoritama. Ako se Silhouette score računa samo nad tačkama koje nisu označene kao šum, može se dobiti optimistična slika o kvalitetu klastera. Zato je u radu dodatno korišćen noise ratio, kao i selection score koji kažnjava modele sa velikim procentom šuma. Ovaj dodatni kriterijum omogućava pravednije poređenje gustinskih algoritama.

10.4. Ograničenja rada

Glavno ograničenje rada je to što je analiza zasnovana na nenadgledanom klasterovanju, dok su stvarne kategorije gramatičkih izraza poznate i semantički definisane. Klasterovanje može otkriti prirodne grupe u prostoru atributa, ali ne garantuje da će te grupe odgovarati unapred definisanim kategorijama.

Drugo ograničenje je izbor atributa i reprezentacije podataka. U radu su korišćeni skalirani atributi i PCA redukovani skup, ali nisu testirane druge metode redukcije dimenzionalnosti ili drugačije reprezentacije karakteristika. Moguće je da bi druge metode, kao što su UMAP ili t-SNE za vizuelizaciju, odnosno dodatne metode ekstrakcije atributa, dale drugačiji uvid u strukturu podataka.

Treće ograničenje odnosi se na izbor algoritama i parametara. Iako je korišćeno pet algoritama i izvršena pretraga relevantnih parametara, prostor mogućih konfiguracija je mnogo veći. Neke drugačije vrednosti parametara ili dodatni algoritmi mogli bi dati bolje rezultate.

Četvrto ograničenje je tumačenje eksternih metrika. Niske vrednosti ARI i NMI ne znače da u podacima ne postoji nikakva struktura, već da pronađena struktura nije snažno usklađena sa stvarnim oznakama. Drugim rečima, klasterovanje može biti korisno za istraživanje podataka, ali nije dovoljan dokaz da se gramatičke kategorije mogu precizno izdvojiti bez nadgledanog učenja.

Ukupno gledano, ograničenja rada ne umanjuju vrednost analize, već ukazuju na to da problem nije trivijalan. Rezultati pokazuju da postoje određene strukture u podacima, ali i da stvarne kategorije izraza lica nisu jasno separabilne korišćenim metodama klasterovanja.

11. Zaključak

U ovom radu izvršena je analiza skupa podataka gramatičkih izraza lica primenom metoda nenadgledanog učenja, odnosno klasterovanja. Cilj je bio da se ispita da li se stvarne gramatičke kategorije izraza lica mogu automatski grupisati na osnovu numeričkih atributa koji ih opisuju.

U okviru rada izvršeno je preprocesiranje početnih podataka, formiran je jedinstven skup podataka, izvršeno je skaliranje atributa i primenjena je PCA redukcija dimenzionalnosti. Nakon toga je implementirano i evaluirano pet algoritama klasterovanja: KMeans, DBSCAN, HDBSCAN, aglomerativno hijerarhijsko klasterovanje i Gaussian Mixture Models. Svaki algoritam je primenjen nad skaliranim skupom podataka i nad PCA redukovanim skupom podataka.

Rezultati su analizirani pomoću internih i eksternih metrika. Interne metrike korišćene su za procenu geometrijskog kvaliteta klastera, dok su eksterne metrike korišćene za poređenje dobijenih klastera sa stvarnim kategorijama izraza lica. Na taj način je omogućeno da se razlikuje interna struktura klastera od njihovog semantičkog poklapanja sa poznatim oznakama.

11.1. Glavni rezultati rada

Glavni rezultat rada jeste zaključak da različiti algoritmi pronalaze različite strukture u istom skupu podataka. Aglomerativno hijerarhijsko klasterovanje ostvarilo je najbolje vrednosti prema Silhouette meri, što ukazuje na dobru unutrašnju razdvojenost klastera. HDBSCAN je dao povoljne rezultate prema Davies-Bouldin indeksu i pokazao se stabilnijim od DBSCAN algoritma, naročito zbog manjeg procenta instanci označenih kao šum.

Sa druge strane, GMM je ostvario najbolje vrednosti eksternih metrika ARI i NMI, posebno nad skaliranim skupom podataka. To ukazuje da se njegove komponente nešto bolje poklapaju sa stvarnim kategorijama izraza lica nego klasteri dobijeni ostalim algoritmima. Međutim, i ove vrednosti su relativno niske, što znači da poklapanje nije snažno.

KMeans je dao stabilne i umerene rezultate, ali nije bio najbolji ni prema internim ni prema eksternim metrikama. DBSCAN je uspeo da pronađe određene guste oblasti, ali je veliki procenat instanci označio kao šum, što ograničava praktičnu upotrebljivost njegovih rezultata u ovom problemu.

Ukupno gledano, rezultati pokazuju da u podacima postoji određena geometrijska struktura, ali da se ta struktura ne poklapa jasno sa stvarnim gramatičkim kategorijama izraza lica.

11.2. Odgovor na istraživačka pitanja

Na osnovu sprovedene analize može se zaključiti da se gramatičke kategorije izraza lica ne mogu jasno izdvojiti isključivo pomoću primenjenih metoda klasterovanja. Algoritmi su pronašli određene grupe u podacima, ali niske vrednosti ARI i NMI metrika pokazuju da te grupe imaju ograničeno poklapanje sa stvarnim oznakama.

Različiti algoritmi nisu pronašli istu strukturu u podacima. Aglomerativno klasterovanje je favorizovalo manji broj dobro razdvojenih klastera, DBSCAN i HDBSCAN su tražili gustinske strukture, dok je GMM modelovao podatke kroz veći broj komponenti. Ove razlike potvrđuju da izbor algoritma značajno utiče na dobijene rezultate.

PCA redukcija dimenzionalnosti imala je pozitivan uticaj na interne metrike kod pojedinih algoritama, posebno kod aglomerativnog klasterovanja, KMeans algoritma i HDBSCAN algoritma. Ipak, PCA nije univerzalno poboljšala sve rezultate, jer je GMM bolje rezultate prema eksternim metrikama ostvario nad skaliranim skupom podataka.

Najbolji algoritam zavisi od kriterijuma posmatranja. Ako se posmatra unutrašnja struktura klastera, najbolje rezultate daju aglomerativno klasterovanje i HDBSCAN. Ako se posmatra poklapanje sa stvarnim kategorijama, najbolji rezultat daje GMM nad skaliranim podacima.

11.3. Moguća unapređenja i budući rad

Jedno moguće unapređenje rada bilo bi ispitivanje dodatnih metoda redukcije dimenzionalnosti, kao što su UMAP ili t-SNE, posebno u svrhu vizuelizacije i boljeg razumevanja lokalne strukture podataka. Takođe bi bilo korisno ispitati dodatne metode ekstrakcije atributa iz originalnih sekvencijalnih podataka, jer trenutna reprezentacija možda ne zadržava sve informacije relevantne za razlikovanje gramatičkih kategorija.

Drugi pravac unapređenja bio bi detaljnija analiza vremenske komponente podataka. Pošto podaci potiču iz izraza lica kroz vreme, moguće je da bi modeli koji eksplicitno uzimaju u obzir sekvencijalnu prirodu podataka dali bolje rezultate od metoda koje instance posmatraju nezavisno.

Takođe, budući rad bi mogao uključiti i nadgledane metode klasifikacije. Pošto su stvarne oznake kategorija dostupne, klasifikacioni modeli bi mogli dati bolji uvid u to koliko se kategorije mogu predvideti na osnovu atributa. U tom slučaju klasterovanje bi moglo da posluži kao početna istraživačka analiza, dok bi klasifikacija predstavljala sledeći korak u izgradnji prediktivnog modela.

Konačno, moguće je proširiti analizu dodatnim algoritmima i širim opsegom parametara. Time bi se proverilo da li postoje konfiguracije koje bolje povezuju unutrašnju strukturu klastera sa stvarnim gramatičkim kategorijama. Ipak, na osnovu sprovedenih eksperimenata može se zaključiti da primenjene metode klasterovanja pružaju koristan uvid u strukturu podataka, ali da same po sebi nisu dovoljne za jasno razdvajanje svih kategorija gramatičkih izraza lica.

12. Literatura

- [1] UCI Machine Learning Repository, Grammatical Facial Expressions Data Set. Dostupno na: <https://archive.ics.uci.edu/dataset/317/grammatical+facial+expressions>
- [2] Scikit-learn documentation, Clustering. Dostupno na: <https://scikit-learn.org/stable/modules/clustering.html>
- [3] HDBSCAN documentation, The hdbscan Clustering Library. Dostupno na: <https://hdbscan.readthedocs.io/>